

Paulinus Alan Sanjaya Jamlu

193114033

UTS 2 Analisis Runtun Waktu


PENYELESAIAN

Untuk melakukan pemodelan dengan metode Box-Jenkin, akan dilakukan dengan 4 tahapan besar, yaitu

1. Identifikasi Model,
2. Pendugaan Model atau Estimasi Model,
3. Pemeriksaan Diagnostik Model, dan
4. Penggunaan Model Untuk Peramalan (forecasting)

1. Identifikasi model

Untuk tahap awal mengidentifikasi data yang akan di proses untuk mengetahui apakah mengandung tren atau musiman, dan akan ditunjukkan grafik plot, grafik ACF dan PACF dari data asli untuk mengetahui apakah data tersebut merupakan data stasioner atau tidak stasioner. Dan jika data sudah stasioner maka proses bisa dilanjutkan ke tahap berikutnya.



Dari plot di atas, terlihat bahwa Jumlah Wisatawan Dalam Negeri Hotel Bintang 1 di DIY tahun 2018 hingga 2022 menunjukkan bahwa data tidak stasioner.

Akan di analisis apakah data set Jumlah Wisatawan Dalam Negeri Hotel Bintang 1 di DIY tahun 2018 hingga 2022 stasioner menggunakan uji ADF (*augmented dicky fuller*)

1) H_0 : Data Tidak Stasioner

H_1 : Data Stasioner

2) Tetapkan uji signifikansi $\alpha = 0.05$

3) Statistik uji

Menggunakan uji Augmented Dicky-Fuller

Dengan daerah penolakannya yaitu H_0 ditolak jika $p\text{-value} < \alpha$

4) Perhitungan



$p\text{-value} = 0.2515 > \alpha = 0.05$

5) Kesimpulan

Karena $p\text{-value} = 0.2515 > \alpha = 0.05$, sehingga H_0 diterima sehingga

menghasilkan **Data tidak Stasioner**.


Akan dipastikan hasilnya menggunakan plot grafik acf dan pacf.



Dari grafik ACF, penurunan nilai terjadi dengan cepat, namun pada grafik PACF, mengindikasikan data set tidak stasioner karena merupakan grafik sinus teredam.

Karena data set di atas tidak stasioner, maka akan di-*differencing* untuk menstasionerkannya.

Setelah data di-*differencing*, berikut adalah grafiknya



Terlihat bahwa data sudah stasioner secara rata-rata dan variansinya.

Lalu akan diperiksa menggunakan uji adf.

Metode Uji Akar Unit (Uji Augmented Dickey Fuller).

Hipotesis yang di uji adalah:

1) H_0 : Data Tidak Stasioner

H_1 : Data Stasioner

2) Tetapkan uji signifikansi $\alpha = 0.05$

3) Statistik uji

Menggunakan uji Augmented Dicky-Fuller

Dengan daerah penolakannya yaitu H_0 ditolak jika $p\text{-value} < \alpha$


4) Perhitungan

$p\text{-value} = 0.01 < \alpha = 0.05$

5) Kesimpulan

Karena nilai $p - value < \alpha = 0.05$, maka H_0 ditolak sehingga hipotesis alternatif diterima (H_1), **data stasioner**.

Akan dipastikan bahwa grafik ACF dan PACF juga menunjukkan hasil yang stasioner.



Mengacu pada grafik ACF dan PACF, tidak terlihat ada pola musiman pada data di atas, meskipun pada grafik terjadi pola naik turun, namun pola tersebut tidak berulang pada jangka waktu tertentu yang membuat data tersebut bukan termasuk data musiman.

2. Estimasi Model

Setelah di-*differencing*, akan dicari nilai p dan q

| model | | q | |
|-------|---|---------|---------|
| p | | 0 | 1 |
| | 0 | (0,1,0) | (0,1,1) |
| | 1 | (1,1,0) | (1,1,1) |

Setelah menentukan nilai p, d, q langkah berikutnya adalah mengestimasi parameter AR dan MA yang dimasukkan dalam model dengan menggunakan program R.

| MODEL | KELAYAKAN | WHITE NOISE | DISTRIBUSI NORMAL | AIC |
|---------------|-------------|-------------|-------------------|---------|
| ARIMA (0,1,0) | TIDAK LAYAK | TIDAK | TIDAK | 1115.53 |
| ARIMA (1,1,0) | TIDAK LAYAK | YA | TIDAK | 1105.94 |
| ARIMA (0,1,1) | LAYAK | YA | YA | 1105.75 |
| ARIMA (1,1,1) | LAYAK | YA | YA | 1107.12 |

Uji signifikansi parameter model

Menentukan apakah model ARIMA memiliki parameter model yang signifikan atau tidak, hal ini dapat dilihat dari p-value. Apabila $p - value < \alpha = 0.05$, maka parameter dari model tersebut signifikan. Berdasarkan kriteria residual white noise, residual model berdistribusi normal, dan AIC terkecil, maka yang memenuhi kriteria tersebut adalah ARIMA (0,1,0). Jadi kita akan mengecek apakah ARIMA (0,1,0) memenuhi signifikansi parameter model atau tidak.

1) Hipotesis

H_0 : Model tidak signifikan

H_1 : model signifikan

2) Tetapkan uji signifikansi $\alpha = 0.05$

3) Statistik uji

Menggunakan uji Augmented Dicky-Fuller

Dengan daerah penolakannya yaitu H_0 ditolak jika $p\text{-value} < \alpha$

4) Perhitungan

$$\mathbf{P\text{-value} = 0.0007 < \alpha = 0.05.}$$

5) Kesimpulan

Karena nilai $p\text{-value} < \alpha = 0.05$, maka H_0 ditolak sehingga hipotesis alternatif diterima (H_1), **model signifikan**. Sehingga model ARIMA (0,1,1) merupakan model terbaik untuk data tersebut.

3. Persamaan matematika

Berikut adalah persamaan matematika untuk mode ARIMA (0,1,1)

$$\text{mal} = -0.4850 = \theta_t$$

$$(1 - B)X_t = (1 - \theta_t B)e_t$$

Substitusi nilai mal

$$(1 - B)X_t = (1 + 0.4850 \times B)e_t$$

$$X_t - X_{t-1} = (1 + 0.4850 \times B)e_t$$

$$\mathbf{X_t = X_{t-1} + e_t + 0.4850e_{t-1}}$$

4. Peramalan

Menggunakan program R untuk meramal 7 bulan kedepan

Model ARIMA (0,1,1)


| Bulan | Jumlah Wisatawan |
|----------|------------------|
| Januari | 8528.797 |
| Februari | 8528.797 |
| Maret | 8528.797 |
| April | 8528.797 |
| Mei | 8528.797 |
| Juni | 8528.797 |
| Juli | 8528.797 |

Karena peramalan dengan model ARIMA (0,1,1) terlihat tidak sesuai karena merupakan nilai konstan, kita akan menggunakan model terbaik ke-2 yaitu ARIMA (1,1,1)


| Bulan | Jumlah Wisatawan |
|----------|------------------|
| Januari | 9054.743 |
| Februari | 8075.582 |
| Maret | 7545.372 |
| April | 7258.266 |
| Mei | 7102.8 |
| Juni | 7018.616 |
| Juli | 6973.031 |

5. Perbandingan

ARIMA (0,1,1)



ARIMA (1,1,1)



6. Kesimpulan

Model ARIMA (0,1,1) merupakan model terbaik untuk data deret waktu kunjungan wisata di Jogja dari data yang sudah tersedia dari tahun 2018 hingga 2022. Namun, Model Arima ini tidak cukup baik untuk memprediksi jumlah wisatawan untuk 7 bulan kedepan. Hal ini bisa disebabkan oleh anomali pada 2019 hingga 2022 karena pandemi virus corona sehingga data wisatawan tidak dapat diprediksi dengan baik.

Lampiran

```
library(forecast)
```

```
Warning: package 'forecast' was built under R version 4.2.3
```

```
Registered S3 method overwritten by 'quantmod':
```

```
  method          from  
as.zoo.data.frame zoo
```

```
library(tseries)
```

```
Warning: package 'tseries' was built under R version 4.2.3
```

1

```
usip = read.csv(file = "D:/Semester VIII/Analisis Runtun Waktu/uts 2/D  
ATA USIP2.csv", header = TRUE, sep = ";")
```

```
attach(usip)
```

```
usip
```

| | TAHUN | BULAN | JUMLAH |
|----|-------|-------|--------|
| 1 | 2018 | jan | 7092 |
| 2 | 2018 | feb | 5278 |
| 3 | 2018 | mar | 6525 |
| 4 | 2018 | apr | 6888 |
| 5 | 2018 | mei | 8646 |
| 6 | 2018 | jun | 10388 |
| 7 | 2018 | jul | 8417 |
| 8 | 2018 | agu | 6877 |
| 9 | 2018 | sep | 743 |
| 10 | 2018 | okt | 698 |
| 11 | 2018 | nov | 9505 |
| 12 | 2018 | des | 1272 |
| 13 | 2019 | jan | 8970 |
| 14 | 2019 | feb | 6676 |
| 15 | 2019 | mar | 10427 |
| 16 | 2019 | apr | 8933 |
| 17 | 2019 | mei | 12299 |
| 18 | 2019 | jun | 14578 |
| 19 | 2019 | jul | 9651 |
| 20 | 2019 | agu | 11844 |
| 21 | 2019 | sep | 11162 |
| 22 | 2019 | okt | 13570 |
| 23 | 2019 | nov | 12757 |
| 24 | 2019 | des | 14699 |
| 25 | 2020 | jan | 5785 |
| 26 | 2020 | feb | 3636 |

$$X_t = (\text{usip\$JUMLAH})_{X_t}$$
[illegible]

```
[49] 5525 5311 5144 5417 7681 3787 6879 5802 5492 6146 617  
6 10863
```

```
# Melakukan tes ADF pada data
```

```
adf.test(Xt)
```

Augmented Dickey-Fuller Test

data: Xt


Dickey-Fuller = -2.7998, Lag order = 3, p-value = 0.2515

alternative hypothesis: stationary

```
# Menampilkan plot data
```

```
par(mfrow=c(1,1))
```

```
plot.ts(Xt)
```





```
# Menampilkan plot ACF dan PACF
```

```
par(mfrow=c(2,1))
```


```
acf(Xt, lag.max = 120)
```

```
pacf(Xt, lag.max = 120)
```



```
# Melakukan diferensiasi pada data untuk membuatnya stasioner
differenced_usip <- diff(Xt)

# Menampilkan plot data yang sudah didiferensiasi
par(mfrow=c(1,1))
plot.ts(differenced_usip)
```



Melakukan tes ADF pada data yang sudah didiferensiasi

```
adf.test(differenced_usip)
```

Warning in adf.test(differenced_usip): p-value smaller than printed p-value

Augmented Dickey-Fuller Test

data: differenced_usip

Dickey-Fuller = -5.2144, Lag order = 3, p-value = 0.01

alternative hypothesis: stationary


Menampilkan plot ACF dan PACF dari data yang sudah didiferensiasi

```
par(mfrow=c(2,1))
```


```
Acf(differenced_usip, lag.max = 120)
```

```
Pacf(differenced_usip, lag.max = 120)
```

Series differenced_usip



Series differenced_usip



```
fit = auto.arima(Xt)
summary(fit)

Series: Xt
ARIMA(0,1,1)

Coefficients:
      ma1
    -0.4855
s.e.    0.1349

sigma^2 = 7635568:  log likelihood = -550.87
AIC=1105.75   AICc=1105.96   BIC=1109.9

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE
Training set 54.28668 2716.809 1949.862 -33.80457 55.76716 0.9057632
              ACF1
Training set -0.001985753

estimasi
#estimasi2
estimasi2=arima(Xt,order=c(0,1,0))
estimasi2
```

```
Call:
arima(x = Xt, order = c(0, 1, 0))
```

```
sigma^2 estimated as 9206750: log likelihood = -556.76, aic = 1115.53
```

```
residual1=resid(estimasi2)
shapiro.test(residual1)
```

Shapiro-Wilk normality test

```
data: residual1
W = 0.94845, p-value = 0.01317
```

```
Box.test(residual1, lag=6, type="Ljung-Box")
```

Box-Ljung test

```
data: residual1
X-squared = 16.507, df = 6, p-value = 0.01128
```

#estimasi2

```
estimasi2=arima(Xt, order=c(1,1,0))
estimasi2
```

```
Call:
arima(x = Xt, order = c(1, 1, 0))
```

```
Coefficients:
      ar1
    -0.4283
s.e.    0.1192
```

```
sigma^2 estimated as 7538668: log likelihood = -550.97, aic = 1105.94
```

```
residual2=resid(estimasi2)
shapiro.test(residual2)
```

Shapiro-Wilk normality test

```
data: residual2
W = 0.95066, p-value = 0.01673
```



```
Box.test(residual2,lag=6,type="Ljung-Box")
```

Box-Ljung test

data: residual2

X-squared = 4.3917, df = 6, p-value = 0.6238

```
#estimasi3
```

```
estimasi3=arima(Xt,order=c(0,1,1))
```

```
estimasi3
```

Call:

```
arima(x = Xt, order = c(0, 1, 1))
```

Coefficients:

ma1

-0.4855

s.e. 0.1349

sigma^2 estimated as 7506151: log likelihood = -550.87, aic = 1105.75

```
residual3=resid(estimasi3)
```

```
shapiro.test(residual3)
```

Shapiro-Wilk normality test

data: residual3

W = 0.96369, p-value = 0.07141

```
Box.test(residual3,lag=6,type="Ljung-Box")
```

Box-Ljung test

data: residual3

X-squared = 4.2163, df = 6, p-value = 0.6474

```
#estimasi4
```

```
estimasi4=arima(Xt,order=c(1,1,1))
```

```
estimasi4
```

Call:

```
arima(x = Xt, order = c(1, 1, 1))
```

Coefficients:

| | ar1 | ma1 |
|------|--------|---------|
| | 0.5415 | -0.9842 |
| s.e. | 0.1574 | 0.1784 |

sigma^2 estimated as 7195012: log likelihood = -550.56, aic = 1107.12

```
residual4=resid(estimasi4)
shapiro.test(residual4)
```

Shapiro-Wilk normality test

data: residual4
W = 0.96979, p-value = 0.1425

```
Box.test(residual4,lag=6,type="Ljung-Box")
```

Box-Ljung test

data: residual4
X-squared = 6.8429, df = 6, p-value = 0.3356

3. Persamaan

ARMA (0,1,1)

```
library(astsa)
```

Warning: package 'astsa' was built under R version 4.3.0

Attaching package: 'astsa'

The following object is masked from 'package:forecast':

gas

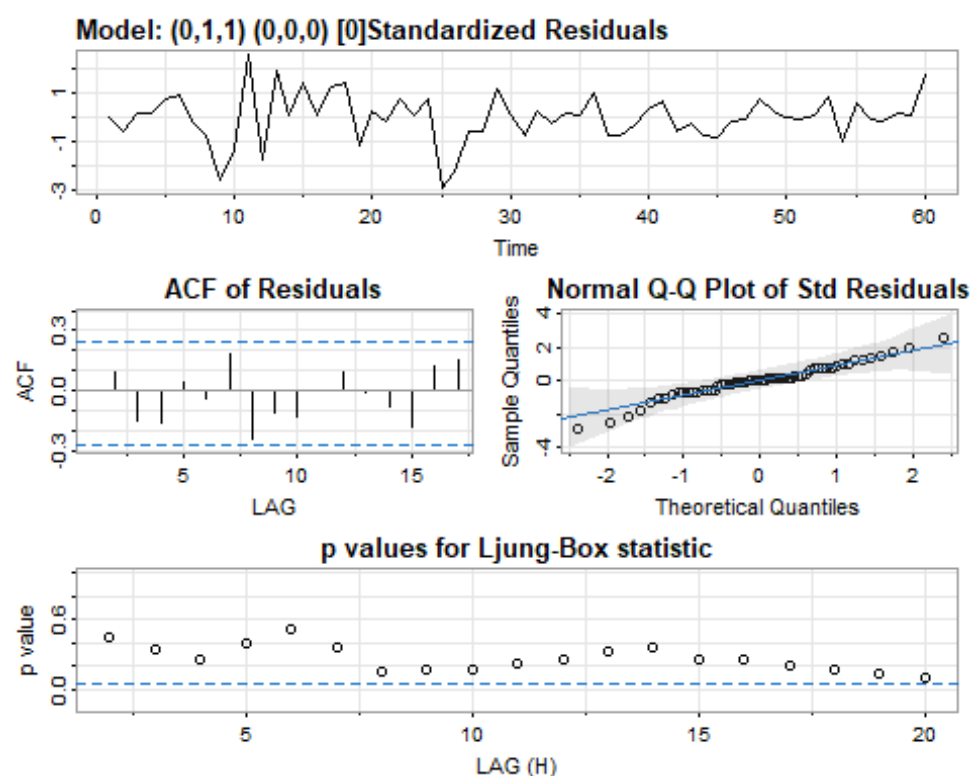
```
Xt3<-sarima(Xt,0,1,1,0,0,0,0)
```

| | | |
|---------|-------|----------------|
| initial | value | 8.017502 |
| iter | 2 | value 7.918634 |
| iter | 3 | value 7.917425 |
| iter | 4 | value 7.916216 |
| iter | 5 | value 7.915639 |
| iter | 6 | value 7.915633 |
| iter | 7 | value 7.915633 |
| iter | 7 | value 7.915633 |
| iter | 7 | value 7.915633 |

```

final value 7.915633
converged
initial value 7.917696
iter 2 value 7.917672
iter 3 value 7.917639
iter 4 value 7.917628
iter 4 value 7.917628
iter 4 value 7.917628
final value 7.917628
converged

```



Xt3\$ttable

| | Estimate | SE | t.value | p.value |
|----------|----------|----------|---------|---------|
| ma1 | -0.4850 | 0.1347 | -3.6010 | 0.0007 |
| constant | 33.0827 | 187.0056 | 0.1769 | 0.8602 |

auto.arima(Xt)

Series: Xt
ARIMA(0,1,1)

Coefficients:
ma1
-0.4855
s.e. 0.1349

```
sigma^2 = 7635568: log likelihood = -550.87  
AIC=1105.75 AICc=1105.96 BIC=1109.9
```

4. Peramalan

```
library(forecast)  
# ARIMA (0,1,1)  
fit <- Arima(Xt, order = c(0, 1, 1))  
forecasted_values <- forecast(fit, h = 7)  
forecasted_values
```

| | Point Forecast | Lo 80 | Hi 80 | Lo 95 | Hi 95 |
|----|----------------|----------|----------|-----------|----------|
| 61 | 8528.797 | 4987.545 | 12070.05 | 3112.9201 | 13944.67 |
| 62 | 8528.797 | 4546.312 | 12511.28 | 2438.1112 | 14619.48 |
| 63 | 8528.797 | 4149.309 | 12908.28 | 1830.9477 | 15226.65 |
| 64 | 8528.797 | 3785.418 | 13272.18 | 1274.4248 | 15783.17 |
| 65 | 8528.797 | 3447.520 | 13610.07 | 757.6550 | 16299.94 |
| 66 | 8528.797 | 3130.733 | 13926.86 | 273.1699 | 16784.42 |
| 67 | 8528.797 | 2831.532 | 14226.06 | -184.4177 | 17242.01 |


```
# Plot  
plot(forecasted_values)
```

```
# ARIMA (1,1,1)  
fit <- Arima(Xt, order = c(1, 1, 1))  
forecasted_values <- forecast(fit, h = 7)  
forecasted_values
```


| | Point Forecast | Lo 80 | Hi 80 | Lo 95 | Hi 95 |
|----|----------------|----------|----------|-----------|----------|
| 61 | 9054.743 | 5548.653 | 12560.83 | 3692.6407 | 14416.85 |
| 62 | 8075.582 | 4053.742 | 12097.42 | 1924.7082 | 14226.46 |
| 63 | 7545.372 | 3365.790 | 11724.95 | 1153.2524 | 13937.49 |
| 64 | 7258.266 | 3023.054 | 11493.48 | 781.0684 | 13735.46 |
| 65 | 7102.800 | 2845.214 | 11360.39 | 591.3842 | 13614.22 |
| 66 | 7018.616 | 2750.594 | 11286.64 | 491.2398 | 13545.99 |
| 67 | 6973.031 | 2699.298 | 11246.76 | 436.9200 | 13509.14 |

```
# Plot  
plot(forecasted_values)
```

Forecasts from ARIMA(0,1,1)




Forecasts from ARIMA(1,1,1)



5. Perbandingan

```
# ARIMA (0,1,1)
library(forecast)
par(mfrow=c(1,1))
fit<-Arima(Xt,order=c(0,1,1))
plot.ts(fit$x,col="red")
lines(fitted(fit),col="blue")
```



```
#ARIMA (1,1,1)
library(forecast)
par(mfrow=c(1,1))
fit<-Arima(Xt,order=c(1,1,1))
plot.ts(fit$x,col="red")
lines(fitted(fit),col="blue")
```

